

Progetto per l'esame di

Apprendimento Automatico e Apprendimento Profondo

Classificazione supervisionata multiclasse sul dataset
Dry Bean del repository UCI (7 varietà di fagioli secchi)

Autore: Andrea Vittorio Balillo — **Matricola:** 0322500157

Corso di Apprendimento Automatico e Apprendimento Profondo

Con implementazione di **entrambe** le opzioni del Task 5: deep learning (a) e spiegabilità con SHAP (b).

1. Introduzione e scelte progettuali

Questo elaborato descrive lo sviluppo di un esperimento completo di **classificazione supervisionata** realizzato in Python. Il lavoro segue puntualmente la traccia d'esame e ne implementa tutti i task; per il Task 5, invece di scegliere una sola opzione, sono state realizzate **entrambe** (deep learning e spiegabilità) per completezza.

1.1 Il dataset scelto

È stato scelto il dataset **Dry Bean Dataset** (UCI ID 602), un dataset di **classificazione multiclasse** del repository UCI. Contiene **13.611 campioni** descritti da **16 feature numeriche** di natura **morfologica**, estratte automaticamente da immagini digitali di legumi: area, perimetro, lunghezza degli assi maggiore e minore, eccentricità, area convessa, diametro equivalente, compattezza, rotondità e quattro *fattori di forma* (ShapeFactor1-4).

Il compito è **classificare** ogni chicco in una delle **7 varietà** di fagiolo secco (*BARBUNYA*, *BOMBAY*, *CALI*, *DERMASON*, *HOROZ*, *SEKER*, *SIRA*). Trattandosi di un problema **multiclasse**, precision, recall, F1 e ROC AUC vengono calcolati con approccio *macro-average* / One-vs-Rest, rendendo l'analisi più articolata rispetto a un caso binario. La scelta del dataset è motivata da: numerosità elevata (oltre 13.000 campioni), assenza di valori mancanti, feature interamente numeriche e interpretabili (adatte a PCA e SHAP) e natura multiclasse, che lo differenzia dai tipici problemi binari.

1.2 Algoritmi e strumenti implementati

Il progetto è articolato nei seguenti componenti:

- **Task 1 — PCA:** analisi della varianza spiegata (scree plot e varianza cumulata), proiezione 2D e analisi dei *loadings* delle feature.
- **Task 2 — Cinque classificatori shallow** (il minimo richiesto era tre): Logistic Regression, SVM con kernel RBF, Random Forest, K-Nearest Neighbors e Naive Bayes gaussiano.
- **Task 3 — Metriche:** precision, recall, F1 (f-measure), accuracy e ROC AUC (macro-average).
- **Task 4 — Visualizzazioni:** matrici di confusione 7×7 e curve ROC macro-average.
- **Task 5a — Deep learning:** rete neurale MLP in PyTorch sugli stessi dati e con la stessa suddivisione train/validation/test.
- **Task 5b — Spiegabilità:** analisi SHAP del modello Random Forest.

Le librerie principali sono **scikit-learn** (PCA, classificatori, metriche), **PyTorch** (deep learning), **SHAP** (spiegabilità) e **matplotlib/seaborn** (visualizzazioni); il dataset è caricato tramite **ucimlrepo** / da CSV locale. Tutti gli esperimenti usano un *random seed* fisso (42) per la piena riproducibilità.

2. Analisi esplorativa e pre-processing

Il dataset è **sbilanciato**: la classe più numerosa è **DERMASON** (3546 campioni, 26.05%), mentre la meno rappresentata è **BOMBAY** (522 campioni, 3.84%). Lo sbilanciamento è gestito tramite **stratificazione** nelle suddivisioni. La Figura 1 mostra la distribuzione delle classi, mentre la Figura 2 riporta la matrice di correlazione: molte feature risultano fortemente correlate (ad es. area, perimetro, area convessa e diametro equivalente), il che giustifica l'uso della PCA.




Figura 1 — Distribuzione delle 7 classi nel dataset.




Figura 2 — Matrice di correlazione delle 16 feature morfologiche.

2.1 Suddivisione dei dati

I dati sono stati suddivisi in modo **stratificato** in tre insiemi. La stessa identica suddivisione è usata da tutti i modelli (shallow e deep learning), come richiesto dalla traccia.

Insieme	N. campioni	Percentuale	Utilizzo
Training	8.166	60%	Addestramento dei modelli
Validation	2.722	20%	Selezione modello / early stopping
Test	2.723	20%	Valutazione finale

Le feature sono state **standardizzate** (media 0, deviazione standard 1) adattando lo *StandardScaler* **solo sul training set** e applicandolo poi a validation e test, così da evitare qualsiasi *data leakage*.

3. Task 1 — Analisi delle feature con la PCA

La **Principal Component Analysis** proietta i dati su componenti ortogonali ordinate per varianza spiegata decrescente. Come mostra la Figura 3, la **prima componente** da sola spiega il **55.33%** della varianza e le **prime due** insieme il **81.85%**. Sono sufficienti **4 componenti** per raggiungere il 95% della varianza totale: la PCA riesce quindi a comprimere efficacemente l'informazione delle 16 feature originali, confermando la loro forte ridondanza.




Figura 3 — Scree plot (sinistra) e varianza cumulata (destra).

La proiezione 2D (Figura 4) è particolarmente istruttiva: pur usando solo due dimensioni si distinguono chiaramente diversi raggruppamenti. La varietà **BOMBAY**, composta dai fagioli più grandi, risulta **nettamente separata** dalle altre lungo entrambe le componenti, mentre le varietà geometricamente simili (es. SIRA e DERMASON) presentano una parziale sovrapposizione. Questo anticipa sia le buone prestazioni complessive dei classificatori sia la principale fonte di confusione residua.



Figura 4 — Proiezione dei dati sulle prime due componenti principali (colore per classe).

L'analisi dei **loadings** (Figura 5) rivela quali feature originali contribuiscono di più alle prime componenti. La PC1 è dominata da misure di **dimensione** del chicco (le più influenti sono: *MajorAxisLength*, *ShapeFactor2*, *Perimeter*), coerentemente con il fatto che essa separa soprattutto varietà grandi da varietà piccole.




Figura 5 — Contributo (loading) delle 10 feature principali su PC1 e PC2.

4. Task 2 e 3 — Classificatori shallow e metriche

Sono stati addestrati **cinque** classificatori sul training set e valutati sul test set. La Tabella seguente riassume le metriche richieste, ordinate per ROC AUC decrescente. Trattandosi di un problema multiclasse, **precision, recall e F1 sono in macro-average** (media non pesata tra le 7 classi) e la **ROC AUC è calcolata One-vs-Rest**.

Modello	Accuracy	Precision	Recall	F1	ROC AUC
SVM (RBF)	0.9214	0.9359	0.9329	0.9341	0.9946
Logistic Regression	0.9199	0.9343	0.9337	0.9337	0.9943
Random Forest	0.9166	0.9314	0.9291	0.9301	0.9929
Naive Bayes	0.8957	0.9099	0.9102	0.9088	0.9912
K-Nearest Neighbors	0.9141	0.9292	0.9249	0.9266	0.9858

Tabella 1 — Metriche dei classificatori shallow sul test set (evidenziato il migliore per ROC AUC).

Tutti i modelli superano l'89% di accuracy e una ROC AUC di 0,98. Il migliore è la **SVM (RBF)**, che raggiunge una ROC AUC di **0.9946**, accuracy 92.14% e F1 macro 0.9341. Le prestazioni molto ravvicinate dei diversi modelli confermano la buona separabilità del problema già osservata nella proiezione PCA.

5. Task 4 — Matrici di confusione e curve ROC

Le matrici di confusione (Figura 6) permettono di analizzare gli errori dei singoli modelli classe per classe. In tutti i modelli la varietà **BOMBAY** è riconosciuta quasi perfettamente, mentre la confusione residua si concentra tra **SIRA** e **DERMASON** e, in misura minore, tra **BARBUNYA** e **CALI**: varietà morfologicamente simili, come già anticipato dalla PCA. Le curve ROC macro-average (Figura 7) confrontano la capacità discriminante complessiva: tutte si avvicinano molto all'angolo in alto a sinistra, indice di prestazioni elevate.




Figura 6 — Matrici di confusione dei cinque classificatori shallow (test set).




Figura 7 — Curve ROC macro-average (OvR) dei classificatori shallow con relativa AUC.

6. Task 5a — Approccio di Deep Learning

È stata implementata una **rete neurale Percettone Multi-Strato (MLP)** in **PyTorch**, addestrata sugli **stessi dati standardizzati** e con la **stessa suddivisione** train/validation/test usata dagli algoritmi shallow, come esplicitamente richiesto dalla traccia.

Architettura: MLP 16-64-32-7 (ReLU, Dropout 0.3/0.2), con uscita a **7 neuroni** (uno per classe) e funzione di perdita *CrossEntropyLoss*. **Addestramento:** ottimizzatore Adam ($lr=1e-3$, weight decay $1e-4$), mini-batch da 64 ed **early stopping** sulla loss di validation (patience 20). L'addestramento si è arrestato dopo **166 epoche**. La Figura 8 mostra le curve di apprendimento: la loss di validation decresce stabilmente senza segni di overfitting marcato, grazie al dropout e all'early stopping.




Figura 8 — Curve di apprendimento (training e validation loss) della rete MLP.

Sul test set la rete ottiene: **accuracy 0.9240**, precision 0.9378, recall 0.9341, F1 0.9355 e **ROC AUC 0.9950** — risultando il **miglior modello in assoluto**, seppur di misura rispetto a SVM e Logistic Regression. La matrice di confusione è riportata in Figura 9.




Figura 9 — Matrice di confusione della rete neurale MLP (test set).

7. Confronto complessivo dei modelli

La Figura 10 sovrappone le curve ROC macro-average di tutti i modelli (shallow e deep learning), mentre la Figura 11 confronta le cinque metriche. La Tabella 2 riporta il ranking finale complessivo.

Modello	Accuracy	Precision	Recall	F1	ROC AUC
MLP (Deep Learning)	0.9240	0.9378	0.9341	0.9355	0.9950
SVM (RBF)	0.9214	0.9359	0.9329	0.9341	0.9946
Logistic Regression	0.9199	0.9343	0.9337	0.9337	0.9943
Random Forest	0.9166	0.9314	0.9291	0.9301	0.9929
Naive Bayes	0.8957	0.9099	0.9102	0.9088	0.9912
K-Nearest Neighbors	0.9141	0.9292	0.9249	0.9266	0.9858

Tabella 2 — Ranking finale di tutti i modelli sul test set (in evidenza la rete di deep learning).




Figura 10 — Curve ROC macro-average di tutti i modelli (shallow + deep learning).




Figura 11 — Confronto delle cinque metriche tra tutti i modelli.

8. Task 5b — Spiegabilità con SHAP

Per rendere **interpretabile** il modello Random Forest è stata applicata la tecnica **SHAP (SHapley Additive exPlanations)**, che assegna a ogni feature un contributo alla predizione basato sui valori di Shapley della teoria dei giochi. In contesto multiclasse SHAP produce un contributo per **ciascuna delle 7 classi**; sono state prodotte tre visualizzazioni complementari.

Il **bar plot** (Figura 13) fornisce il ranking delle feature per importanza media assoluta aggregata su tutte le classi, mentre il **beeswarm plot** (Figura 12) mostra importanza e direzione dell'effetto delle feature per la classe di riferimento *DERMASON* (la più numerosa). Le feature più determinanti risultano *Perimeter*, *MajorAxisLength*, *ShapeFactor1* — coerenti con l'analisi PCA, che individuava nelle misure di dimensione e forma i fattori principali.




Figura 13 — SHAP: importanza globale media assoluta delle feature (media su tutte le classi).




Figura 12 — SHAP beeswarm plot per la classe 'DERMASON': importanza e direzione dell'effetto delle feature.

Il **waterfall plot** (Figura 14) scompone infine la predizione per un **singolo campione**, mostrando come ogni feature spinga la probabilità della classe di riferimento sopra o sotto il valore atteso del modello. Questo livello di trasparenza consente di comprendere e giustificare le singole decisioni del classificatore.




Figura 14 — SHAP waterfall plot: spiegazione di una singola predizione.

9. Conclusioni

Il progetto ha implementato un esperimento completo di classificazione **multiclasse** sul dataset UCI *Dry Bean*, coprendo tutti i task della traccia e realizzando entrambe le opzioni del Task 5. I principali risultati sono:

- La **PCA** comprime le 16 feature in poche componenti (4 per il 95% della varianza) e mostra classi in larga parte separabili già in 2D (81.85% di varianza spiegata dalle prime due componenti), con la varietà BOMBAY nettamente distinta.
- Tutti i **classificatori shallow** ottengono ottime prestazioni; la **SVM (RBF)** è la migliore con ROC AUC 0.9946, coerentemente con la buona separabilità dei dati.
- La **rete neurale MLP** è il modello migliore in assoluto (ROC AUC 0.9950, accuracy 92.40%), pur con un margine minimo: su dati tabellari ben strutturati i modelli shallow restano molto competitivi rispetto al deep learning.
- L'analisi **SHAP** individua nelle feature di dimensione e forma del chicco (*Perimeter*, *MajorAxisLength*, *ShapeFactor1*) i fattori più determinanti, aggiungendo trasparenza alle decisioni del modello.

In sintesi, le feature morfologiche permettono di distinguere con elevata affidabilità le varietà di fagioli; la confusione residua riguarda quasi esclusivamente varietà geometricamente simili. Modelli shallow ben regolarizzati e rete neurale offrono prestazioni sostanzialmente equivalenti, e l'analisi di spiegabilità fornisce l'interpretabilità dei risultati.

Struttura della consegna e riproducibilità

Il codice è contenuto nel notebook **notebook_a_balillo_0322500157.ipynb** (eseguibile dall'inizio alla fine); il dataset è nel file **dry_bean.csv**, le figure nella cartella **figures/** e le metriche in **results.json**. Le dipendenze sono elencate in **requirements.txt**. L'esperimento usa un seed fisso (42) per garantire risultati riproducibili.