UNIVERSITÀ TELEMATICA SAN RAFFAELE ROMA

Corso di Apprendimento Automatico e Apprendimento Profondo

0322509INGINF05

PROGETTO DI MACHINE LEARNING

SUL BANK MARKETING DATASET

Docente

Dott.ssa Noemi Scarpato

Studente

Matteo Personnettaz

Matricola 0322500013

Anno Accademico 2025/2026

Indice generale

INTRODUZIONE **4**
Definizione di Machine Learning e classificazione 4
STRUMENTI UTILIZZATI **4**
DESCRIZIONE DEL DATASET (DS) **6**
Analisi della variabile target 6
Criticità del dataset 7
PREPROCESSING DEI DATI **7**
RIDUZIONE DELLA DIMENSIONALITÀ CON PCA **8**
SVILUPPO **9**
1. Analisi delle feature del dataset tramite PCA 9
2. Algoritmi di classificazione 12
3. Metriche di valutazione 13
4. Matrice di confusione e ROC AUC Curve 14
5. Approccio di spiegabilità: SHAP 17
6. Approfondimento: verifica della robustezza tramite cross-validation 21
CONCLUSIONI **22**

Indice delle figure

Figura 1 - Distribuzione della variabile target (y).....7
Figura 2: Grafico sulle prime due componenti principali della PCA, in base alla variabile target.....10
Figura 3: Scree plot della varianza spiegata cumulativa delle componenti principali della PCA.....11
Figura 4: Tabella riassuntiva delle metriche di valutazione dei tre modelli di classificazione: accuracy, precision, recall, F1-score e ROC AUC.....14
Figura 5: Matrice di confusione del modello Logistic Regression.....15
Figura 6: Matrice di confusione del modello K-Nearest Neighbors.....15
Figura 7: Matrice di confusione del modello Support Vector Machine.....16
Figura 8: Curve ROC dei modelli di classificazione implementati.....17
Figura 9: Summary plot SHAP.....19
Figura 10: Bar plot globale SHAP.....20
Figura 11: Waterfall plot locale.....21

Introduzione

Il presente elaborato è stato realizzato nell'ambito del corso di *Apprendimento Automatico e Apprendimento Profondo* tenuto dalla Dott.ssa Noemi Scarpato presso l'Università Telematica San Raffaele di Roma. L'esame finale è sviluppato in una parte teorica e una parte progettuale.

Il presente elaborato si focalizza sulla realizzazione del progetto pratico il cui obiettivo è sviluppare un sistema di classificazione automatica in grado di classificare automaticamente dei dati grazie all'utilizzo delle tecniche di Machine Learning. In particolare, il modello creato dovrà essere capace di analizzare il dataset in maniera coerente e seguendo le metriche di valutazione.

Definizione di Machine Learning e classificazione

Prima di analizzare lo sviluppo, è importante capire a cosa ci riferiamo parlando di apprendimento automatico.

Il Machine Learning, o apprendimento automatico, è un insieme di tecniche che permette ad un sistema informatico di imparare dai propri dati, individuando pattern ricorrenti e migliorando nel tempo le sue prestazioni. Una volta addestrato, il modello è in grado di generalizzare le informazioni note, risultando applicabile a nuove casistiche appartenenti allo stesso dominio senza dover essere nuovamente programmato.

Tra le principali applicazioni del Machine Learning rientrano i problemi di classificazione, il cui obiettivo è assegnare ogni elemento a una specifica categoria sulla base delle sue caratteristiche. Nel presente progetto analizzeremo questo problema sviluppandolo in diverse fasi: l'analisi del dataset, la riduzione della dimensionalità, l'addestramento dei modelli e la valutazione delle prestazioni mediante metriche e strumenti grafici.

L'obiettivo finale è l'individualizzazione di un modello più efficace e la comprensione del contributo delle singole feature nel processo decisionale.

Strumenti utilizzati

Vista la sua semplicità sintattica e la vasta disponibilità di librerie pre compilate e dedicate all'analisi dei dati e al Machine Learning, è stato utilizzato il linguaggio di programmazione Python.

Inoltre, è stato configurato un ambiente di lavoro dedicato tramite Anaconda all'interno del quale sono state installate tutte le librerie necessarie al progetto.

PyCharm, software che offre ottimi strumenti avanzati per la scrittura e il debugging del codice, è stato utilizzato come IDE per lo sviluppo in modo da facilitare l'individuazione di eventuali errori durante la progettazione.

Di seguito vengono riportate le principali librerie Python:

- ***Pandas***: libreria utilizzata per la gestione e manipolazione dei dati in formato tabella, è stata utilizzata per la creazione del DataFrame a partire dal dataset Bank Marketing e per l'analisi preliminare dei dati (visualizzazione, descrizione e struttura);
- ***Numpy***: libreria dedicata alle operazioni matematiche e statistiche, è stata utilizzata nel progetto per la PCA e per tutte le variabili calcolate;
- ***Ucimlrepo***: libreria utilizzata per la selezione e il caricamento del dataset utilizzato nello sviluppo del progetto, in particolare il dataset Bank Marketing.
- ***Scikit-learn***: libreria principale per il ML. All'interno del progetto, è stata utilizzata per lo split del dataset in training e test set (train_test_split), per il StandardScaler (Standardizzazione delle feature), per applicare la PCA, per l'implementazione dei 3 algoritmi di classificazione (Logistic Regression, KNN, SVM) e per il calcolo delle metriche di valutazione e delle curve ROC;
- ***Matplotlib***: libreria specifica per la creazione di grafici, è stata utilizzata per illustrare, le prestazioni dei vari modelli e le curve ROC mediante grafici;
- ***Seaborn***: libreria dipendente da Matplotlib, utilizzata per le rappresentazioni dei grafici come quelli della PCA e delle matrici di confusione. Permette di ottenere visualizzazioni più avanzate e leggibili per la mente umana;
- ***SHAP***: metodo di interpretazione dei modelli di Machine Learning, utilizzato tramite l'omonima libreria Python per quantificare il contributo delle singole feature al comportamento del modello.

Infine, durante lo sviluppo del progetto è stato utilizzato anche l'IA di ChatGPT. Questo strumento è stato utilizzato per fornire supporto decisionale e per un'analisi critica delle soluzioni, favorendo un confronto tra diverse idee.

Descrizione del Dataset (DS)

Dopo un'analisi dei dataset disponibili all'interno del repository UCI è stato scelto il **Bank Marketing Dataset** poiché rappresenta un problema reale di classificazione binaria basato su dati raccolti durante campagne di marketing diretto di un istituto bancario.

Il dataset ha l'obiettivo di prevedere se un cliente sottoscriverà o meno un deposito a termine sulla base di un insieme di informazioni anagrafiche, economiche e relative alle precedenti interazioni con la banca. Questo è composto da circa 45.000 osservazioni (righe) e 16 variabili descrittive (feature) oltre alla variabile target.

Le feature presenti sono di natura mista e comprendono variabili numeriche quali età, saldo bancario e durata della chiamata e variabili categoriche come professione, stato civile, livello di istruzione e tipo di contatto.

Le variabili numeriche assumono valori quantitativi, continui o discreti e possono essere utilizzate direttamente dagli algoritmi di Machine Learning previa eventuale standardizzazione. Le variabili categoriche, invece, rappresentano informazioni qualitative e non possono essere utilizzate direttamente dai modelli, rendendo necessaria una fase di trasformazione in formato numerico utilizzando opportune tecniche di encoding. L'eterogeneità delle feature rappresenta un aspetto rilevante del dataset in quanto richiede l'applicazione di tecniche di preprocessing adeguate per garantire un corretto addestramento dei modelli e rende il dataset particolarmente interessante dal punto di vista metodologico poiché richiede operazioni di preprocessing articolate prima dell'addestramento dei modelli, tra cui la gestione dei valori mancanti, la codifica delle variabili categoriche e la standardizzazione delle feature numeriche.

Analisi della variabile target

La variabile target del dataset è rappresentata dalla colonna "y", che indica l'esito della campagna di marketing, dove "*yes*" rappresenta il cliente che ha sottoscritto il deposito e "*no*" il cliente che non l'ha sottoscritto.

Per comprendere la natura del problema è stata analizzata la distribuzione delle classi mediante il conteggio delle occorrenze.

L'analisi ha evidenziato una distribuzione fortemente sbilanciata, con una prevalenza significativa della classe negativa ("*no*") rispetto alla classe positiva ("*yes*"), come mostrato in ***Figura 1***.

Questo aspetto risulta particolarmente rilevante poiché un dataset sbilanciato può influenzare le prestazioni dei modelli di classificazione. In questi contesti, infatti, la sola *accuracy* non è sufficiente a

valutare correttamente il modello, rendendo necessario l'utilizzo di metriche più informative come precision, recall e F1-score.

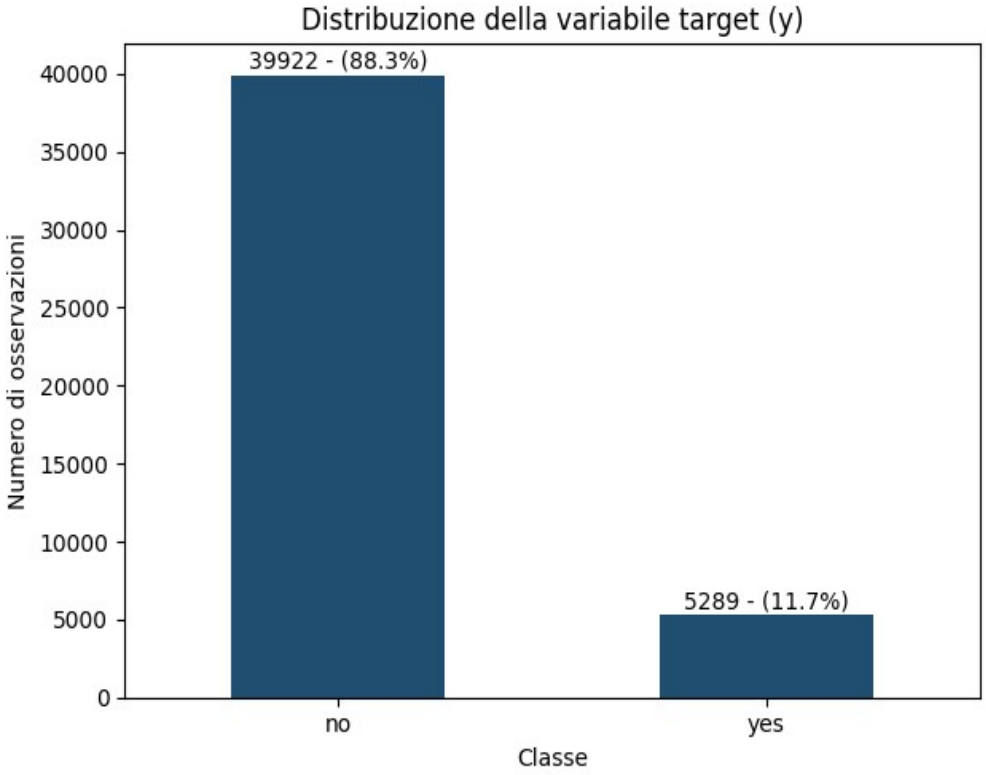

Figura 1 - Distribuzione della variabile target (y)

Criticità del dataset

Durante l'analisi preliminare del dataset è stata individuata una criticità rilevante nella variabile "duration" che rappresenta la durata della chiamata effettuata al cliente.

Questa variabile risulta fortemente correlata all'esito della campagna poiché le chiamate più lunghe sono generalmente associate a una maggiore probabilità di sottoscrizione del deposito.

Tuttavia, essa introduce un possibile problema di data leakage dato che il suo valore è disponibile solo successivamente all'interazione con il cliente e non può quindi essere utilizzato in un contesto predittivo reale.

Preprocessing dei dati

Prima di procedere con l'addestramento dei modelli di classificazione è necessario svolgere una fase di preprocessing dei dati. Si tratta di un insieme di operazioni finalizzate a trasformare il dataset grezzo in una rappresentazione adatta all'utilizzo da parte degli algoritmi di Machine Learning. Come

evidenziato durante il corso, il preprocessing costituisce una fase fondamentale del workflow progettuale poiché la qualità dei dati in ingresso influenza in maniera diretta l'efficacia del modello finale secondo il principio del *garbage in, garbage out*.

Nel caso specifico del Bank Marketing Dataset, l'analisi preliminare delle feature ha evidenziato la presenza di valori mancanti in alcune variabili categoriche, in particolare nelle colonne poutcome, contact, education e job. Per evitare la perdita di osservazioni e mantenere l'informazione disponibile, questi valori sono stati gestiti sostituendoli con una modalità categoriale esplicita, denominata "missing", prima della fase di codifica.

Successivamente, la variabile target è stata trasformata in formato binario, associando il valore 0 alla classe "no" e il valore 1 alla classe "yes". Al contrario, le feature categoriche sono state convertite in formato numerico mediante la tecnica One-Hot Encoding in modo da ottenere un dataset uniforme, interamente numerico e compatibile con le successive fasi di analisi.

Per le variabili numeriche è molto importante la fase di standardizzazione che consente di trasformare i dati in modo da avere media nulla e deviazione standard unitaria. Tale operazione risulta essenziale quando le feature presentano scale di misura differenti, poiché evita che le variabili con valori numericamente più elevati influenzino in modo sproporzionato il processo di apprendimento. In questo progetto, la standardizzazione verrà applicata prima della PCA e dei modelli sensibili alla scala delle variabili.

Nel complesso, il preprocessing ci ha permesso di ottenere una rappresentazione coerente, numerica e utilizzabile del dataset, che è fondamentale per le successive fasi di riduzione della dimensionalità, classificazione e interpretazione.

Riduzione della dimensionalità con PCA

Un ulteriore passaggio teorico rilevante nel presente progetto è rappresentato dalla riduzione della dimensionalità mediante la Principal Component Analysis (PCA). Si tratta di una tecnica di apprendimento non supervisionato che consente di trasformare un insieme di variabili potenzialmente correlate in un nuovo insieme di variabili linearmente non correlate dette componenti principali. Lo scopo della tecnica è proiettare i dati in uno spazio a dimensionalità inferiore, preservando quanto più possibile l'informazione contenuta nel dataset ed espressa in termini di varianza.

L'utilizzo della PCA risulta particolarmente utile in ambito esplorativo poiché permette di sintetizzare l'informazione contenuta in molte feature e di rappresentare i dati in uno spazio bidimensionale o tridimensionale più facilmente interpretabile. In questo modo è possibile osservare la distribuzione

delle istanze, individuare eventuali raggruppamenti e ottenere una prima indicazione sulla separabilità tra le classi. Nelle dispense del corso viene infatti evidenziato come la PCA possa essere utilizzata per semplificare l'analisi di dataset complessi, facilitare la visualizzazione dei dati ad alta dimensionalità e ridurre il rumore.

La qualità della rappresentazione ottenuta tramite PCA viene generalmente valutata attraverso il rapporto di varianza spiegata che indica quanta parte dell'informazione totale del dataset è catturata da ciascuna componente principale. A questo proposito è possibile distinguere tra varianza spiegata individuale, riferita a una singola componente, e varianza spiegata cumulativa, ottenuta sommando il contributo delle componenti considerate. Questo criterio consente di comprendere quante componenti siano necessarie per mantenere una quota significativa dell'informazione originaria.

Dato che la PCA è sensibile alla scala delle variabili, prima della sua applicazione è generalmente necessaria una fase di standardizzazione delle feature così da garantire che ciascuna variabile contribuisca in modo equilibrato alla costruzione delle componenti principali. In questo elaborato, la PCA viene quindi introdotta come strumento teorico e metodologico utile per supportare la successiva analisi esplorativa delle feature in coerenza con quanto richiesto dalla traccia progettuale.

Sviluppo

Descriviamo ora il processo sperimentale svolto sul Bank Marketing Dataset, coerentemente con i punti richiesti dalla traccia progettuale. Dopo una fase preliminare di preparazione dei dati, l'analisi è stata articolata in cinque passaggi principali: applicazione della PCA per l'analisi delle feature, addestramento di tre modelli di classificazione, valutazione mediante metriche quantitative, rappresentazione dei risultati attraverso matrici di confusione e curve ROC, e infine interpretazione del modello tramite SHAP.

Ogni fase è stata progettata con l'obiettivo di costruire un modello efficace, garantendo al tempo stesso una comprensione approfondita del comportamento dei dati e delle decisioni del modello.

1. Analisi delle feature del dataset tramite PCA

Dopo aver inizialmente analizzato la struttura del dataset è stata applicata la Principal Component Analysis (PCA) per ottenere una rappresentazione sintetica delle feature.

Nel presente progetto la PCA non è stata applicata direttamente al dataset grezzo, ma a una sua versione preprocessata. Dopo aver separato le feature dalla variabile target, è stata effettuata un'analisi preliminare dei tipi di dato che ha evidenziato la presenza di variabili numeriche e categoriche. Sono

inoltre emersi valori mancanti in alcune feature categoriche, in particolare nelle colonne poutcome, contact, education e job. Per evitare la perdita di dati, tali valori sono stati sostituiti con il termine "missing". Successivamente, la variabile target è stata codificata in forma binaria, mentre le feature categoriche sono state trasformate in formato numerico tramite One-Hot Encoding e ottenendo così un dataset interamente numerico, requisito necessario per l'applicazione della PCA.

Prima della riduzione dimensionale, tutte le feature sono state standardizzate, così da garantire che ciascuna variabile contribuisse in modo equilibrato alla costruzione delle componenti principali. Standardizzate le feature, la PCA è stata applicata mantenendo due componenti principali con l'obiettivo di ottenere una rappresentazione bidimensionale del dataset.

Le prime due componenti principali spiegano rispettivamente il 7,22% e il 6,36% della varianza totale, per una quota complessiva pari al 13,59%. Questo risultato indica che la proiezione in due dimensioni è utile a fine esplorativo ma non è sufficiente a rappresentare l'intera struttura del dataset.

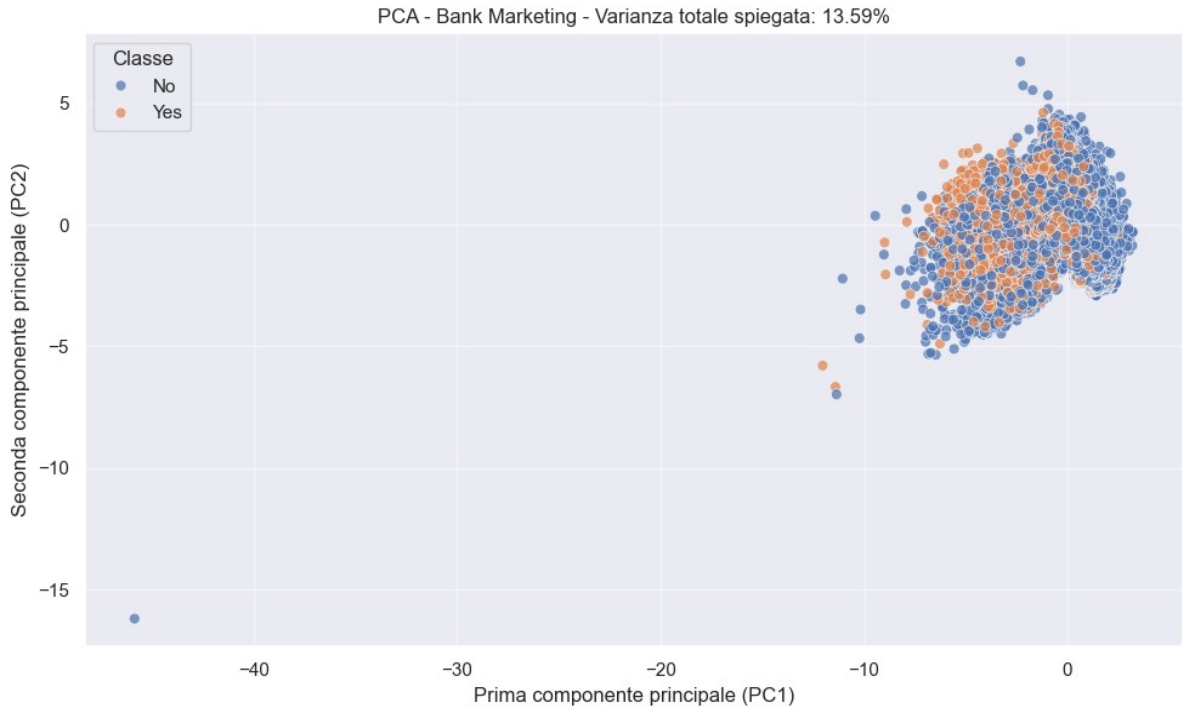

Figura 2: Grafico sulle prime due componenti principali della PCA, in base alla variabile target.

La distribuzione dei campioni nello spazio definito da PC1 e PC2 è stata rappresentata graficamente nella ***Figura 2***, distinguendo le osservazioni in base alla classe della variabile target. Il grafico evidenzia una forte sovrapposizione tra le classi "yes" e "no", segnalando che le due componenti

principali non consentono una separazione netta dei gruppi. Questo suggerisce che la distinzione tra i clienti che sottoscrivono il deposito e i clienti che non lo sottoscrivono non può essere colta efficacemente attraverso una rappresentazione bidimensionale basata soltanto sulle prime due componenti principali.

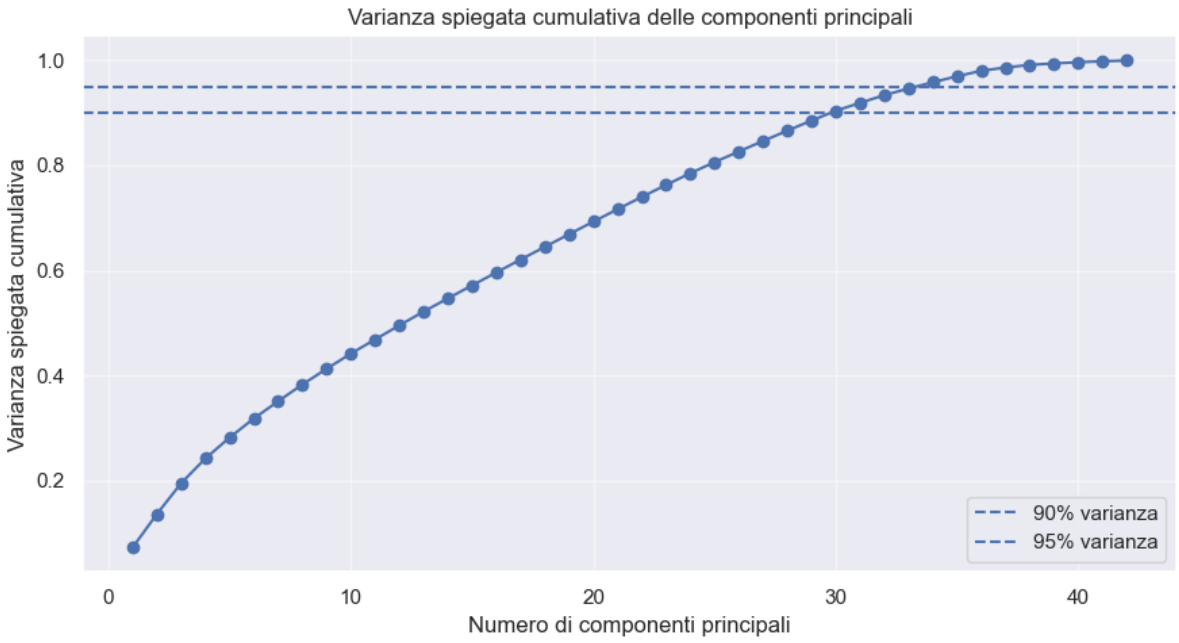

Figura 3: Scree plot della varianza spiegata cumulativa delle componenti principali della PCA.

Per approfondire ulteriormente la distribuzione dell'informazione nel dataset è stato inoltre costruito uno scree plot della varianza spiegata cumulativa (***Figura 3***). Questo mostra che la varianza cresce gradualmente e che per raggiungere circa il 90% della varianza spiegata sono necessarie circa 30 componenti principali, mentre per superare il 95% ne occorrono circa 33. Questo conferma che l'informazione del dataset non è concentrata nelle prime componenti, ma risulta distribuita su un numero più ampio di dimensioni.

Nel complesso, l'analisi tramite PCA ha svolto un ruolo prevalentemente esplorativo e interpretativo: ha permesso di visualizzare sinteticamente il dataset, verificare il limitato grado di separabilità delle classi nelle prime due componenti e osservare come la struttura informativa del Bank Marketing Dataset risulti distribuita su molte dimensioni.

2. Algoritmi di classificazione

Successivamente sono stati implementati tre algoritmi di classificazione supervisionata. La scelta è ricaduta su Logistic Regression, K-Nearest Neighbors (KNN) e Support Vector Machine (SVM), con l'obiettivo di confrontare approcci differenti per struttura e principio di funzionamento, così da valutare quale risulti più adatto al problema di classificazione binaria per il Bank Marketing Dataset. Tale selezione consente di mettere a confronto un modello lineare, un modello basato sulla distanza e un modello capace di apprendere una frontiera di separazione più flessibile.

La *Logistic Regression* è stata considerata come modello lineare di riferimento, utile per fornire una linea base interpretabile e facilmente confrontabile con metodi più complessi.

Il *K-Nearest Neighbors* è stato invece selezionato perché è fondato sulla distanza tra osservazioni. Questo lo rende particolarmente sensibile alla struttura locale dei dati e, quindi, interessante in un contesto in cui le feature, dopo il preprocessing, sono state rese confrontabili tramite standardizzazione. Inoltre, tale modello consente di catturare relazioni non lineari tra i dati, risultando utile come termine di confronto rispetto a un classificatore lineare.

Infine, la *Support Vector Machine* è stata inclusa in quanto rappresenta uno dei modelli più solidi nei problemi di classificazione binaria, grazie alla sua capacità di individuare un confine di separazione efficace tra le classi massimizzando il margine. In accordo con gli esempi presenti nelle dispense, è stata utilizzata una SVM con *kernel RBF*, configurazione particolarmente adatta a cogliere eventuali relazioni non lineari tra le feature.

I modelli non sono stati addestrati sul dataset grezzo, ma sulla versione preprocessata e codificata delle feature. In particolare, dopo la gestione dei valori mancanti nelle variabili categoriche, la trasformazione delle stesse in formato numerico mediante One-Hot Encoding e la codifica binaria della variabile target, è stato ottenuto un dataset interamente numerico e compatibile con i classificatori selezionati.

Successivamente, il dataset è stato suddiviso in training set e test set mediante una partizione stratificata così da preservare la distribuzione originaria delle classi. Questa scelta è risultata importante in presenza di una variabile target sbilanciata in quanto consente di effettuare una valutazione comparativa più affidabile dei modelli. La suddivisione è stata definita fissando il parametro random state a 42, in linea con quanto raccomandato nelle dispense del corso.

In merito alle impostazioni iniziali dei classificatori, la Logistic Regression è stata configurata con un numero massimo di iterazioni pari a 2000 per evitare problemi di convergenza. Il KNN è stato

inizializzato con 5 vicini mentre la SVM è stata implementata con kernel RBF e con la stima delle probabilità abilitata per consentire successivamente il calcolo della curva ROC e della metrica AUC.

Con l'utilizzo di questi tre classificatori è stato creato un modello solido per la fase successiva di valutazione quantitativa.

3. Metriche di valutazione

Una volta addestrati i tre classificatori, le loro prestazioni sono state valutate mediante un insieme di metriche standard per problemi di classificazione binaria: accuracy, precision, recall, F1-score e ROC AUC.

La metrica *accuracy* misura la proporzione complessiva di predizioni corrette ma può risultare ingannevole in presenza di dataset sbilanciati. Per questo motivo è opportuno affiancarla a metriche più informative quali precision, recall e F-measure. La prima indica la quota di esempi predetti come positivi che sono effettivamente positivi, la seconda misura la capacità del modello di individuare correttamente i positivi reali e la terza rappresenta una sintesi equilibrata tra queste due grandezze. A tali metriche è stata affiancata la ROC AUC che fornisce una misura della capacità discriminante complessiva del classificatore al variare della soglia decisionale.

Nel Bank Marketing Dataset questo aspetto risulta particolarmente rilevante poiché la classe positiva corrispondente ai clienti che sottoscrivono il deposito è nettamente minoritaria rispetto alla classe negativa. In un contesto di questo tipo, un modello potrebbe ottenere un valore di accuracy elevato, limitandosi anche a predire prevalentemente la classe dominante. Per questo motivo, il confronto tra i modelli non è stato basato unicamente sull'accuratezza ma su un insieme più ampio di indicatori, in grado di fornire una valutazione più robusta del comportamento dei classificatori.

I risultati ottenuti mostrano che Logistic Regression e SVM presentano prestazioni complessivamente buone, con valori di accuracy superiori al 90% e valori di ROC AUC prossimi a 0,90. In particolare, la Logistic Regression ha ottenuto un'accuracy pari a 0,9014, una precision pari a 0,6451, una recall pari a 0,3488, un F1-score pari a 0,4528 e una ROC AUC pari a 0,9054. La SVM ha mostrato un'accuracy leggermente superiore (0,9021) e una precision più elevata (0,6740), ma una recall inferiore (0,3166), con conseguente F1-score più basso (0,4309) e una ROC AUC lievemente inferiore (0,9043). Il KNN è risultato invece il modello meno efficace nel training set, con accuracy pari a 0,8946, F1-score pari a 0,4135 e ROC AUC pari a 0,8056.

L'analisi comparativa evidenzia come la Logistic Regression rappresenti, in questa fase del progetto, il miglior compromesso complessivo tra capacità discriminante e bilanciamento tra precision e recall.

Questo risultato è particolarmente significativo: mostra come il modello con l'accuracy più alta non coincida necessariamente con quello globalmente migliore. Nel caso specifico, infatti, la SVM presenta un'accuratezza leggermente superiore, ma la Logistic Regression ottiene i valori migliori sia in termini di F1-score sia di ROC AUC, risultando il classificatore più solido rispetto agli obiettivi dell'analisi.

Nel complesso, la valutazione quantitativa ha confermato quanto sia importante ed essenziale l'utilizzo di più metriche simultaneamente, soprattutto in presenza di classi così sbilanciate come nel nostro dataset, ed ha permesso di individuare una prima classifica dei modelli, che verrà ulteriormente approfondita nella successiva analisi tramite matrici di confusione e curve ROC.

Di seguito viene riportata la tabella riassuntiva delle metriche di valutazione:

Tabella riassuntiva delle metriche di valutazione

	Accuracy	Precision	Recall	F1-score	ROC AUC
Logistic Regression	0.9014	0.6451	0.3488	0.4528	0.9054
SVM	0.9021	0.674	0.3166	0.4309	0.9043
KNN	0.8946	0.5926	0.3176	0.4135	0.8056

Figura 4: Tabella riassuntiva delle metriche di valutazione dei tre modelli di classificazione: accuracy, precision, recall, F1-score e ROC AUC.

4. Matrice di confusione e ROC AUC Curve

Per completare l'analisi quantitativa dei modelli di classificazione, sono state considerate anche le matrici di confusione e le curve ROC.

La matrice di confusione costituisce uno strumento particolarmente utile per interpretare il comportamento effettivo di un classificatore, poiché consente di distinguere tra veri positivi (TP), veri negativi (TN), falsi positivi (FP) e falsi negativi (FN). Come evidenziato anche nelle dispense del corso, una buona matrice di confusione è il più possibile vicina a una struttura diagonale, mentre gli elementi fuori diagonale rappresentano errori di classificazione.

Con un problema binario come il Bank Marketing Dataset, l'analisi della matrice di confusione permette di valutare in modo immediato se il modello tende a favorire la classe maggioritaria o se riesce a riconoscere in maniera efficace anche la classe positiva. I risultati ottenuti mostrano che tutti e tre i modelli classificano correttamente la maggior parte dei casi appartenenti alla classe negativa,

mentre incontrano maggiori difficoltà nel riconoscimento della classe positiva, coerentemente con quanto osservato nella variabile target.

In particolare, la Logistic Regression risulta il modello più equilibrato, poiché mantiene un numero contenuto di falsi positivi e, al tempo stesso, ottiene il numero più alto di veri positivi (369) tra i tre classificatori. La SVM presenta invece un comportamento più conservativo: riduce ulteriormente i falsi positivi (162), ma al prezzo di un numero inferiore di veri positivi (335) e di un numero più elevato di falsi negativi. Il KNN, infine, mostra complessivamente il comportamento meno efficace, con un numero più alto di errori e una capacità inferiore di intercettare la classe positiva. Le matrici di confusione confermano dunque quanto già emerso dalle metriche quantitative: i modelli più efficaci sono Logistic Regression e SVM, mentre il KNN risulta meno competitivo nel training set considerato.

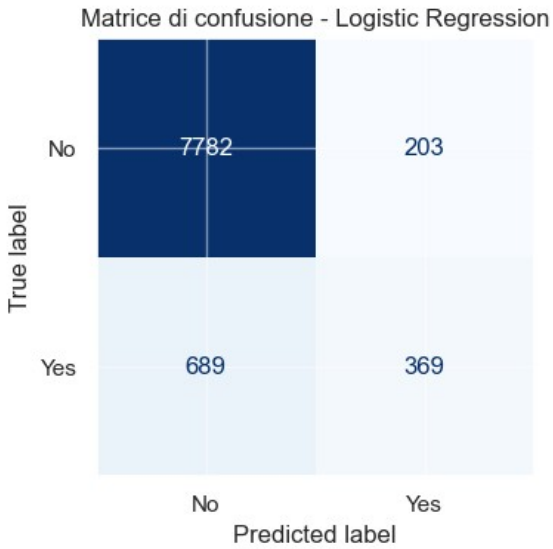

Figura 5: Matrice di confusione del modello Logistic Regression

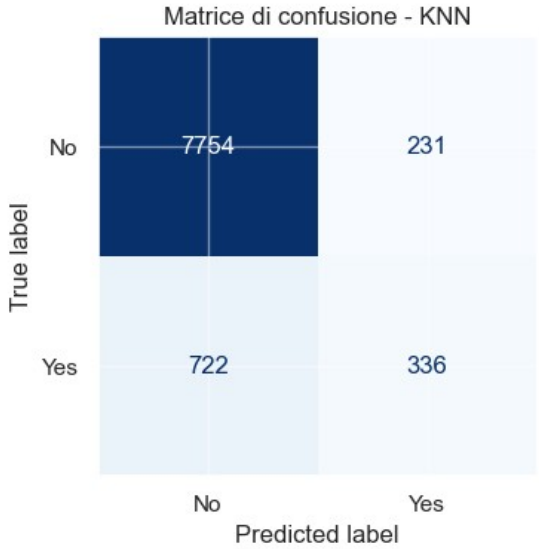

Figura 6: Matrice di confusione del modello K-Nearest Neighbors

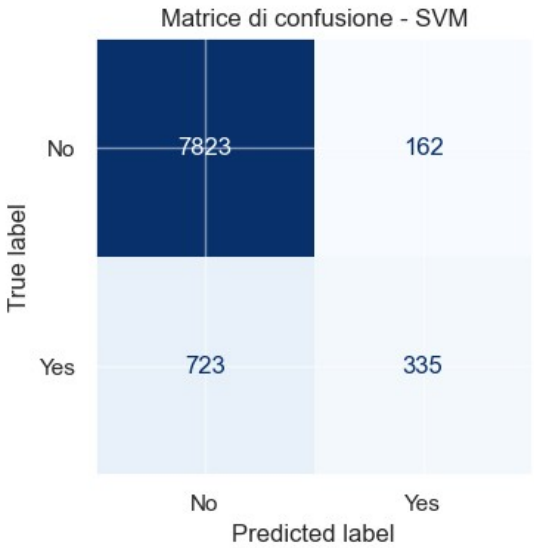

Figura 7: Matrice di confusione del modello Support Vector Machine

Accanto alle matrici di confusione, sono state analizzate anche le curve ROC (Receiver Operating Characteristic) che mettono in relazione il True Positive Rate con il False Positive Rate al variare della soglia decisionale del modello. La relativa area sottesa (ROC AUC) indica come un valore di AUC vicino a 0,5 corrisponde a un classificatore casuale, mentre valori prossimi a 1 indicano un classificatore quasi perfetto.

Le curve ROC ottenute confermano i risultati già osservati nelle metriche quantitative. In particolare, la Logistic Regression ha ottenuto il valore di AUC più elevato (0,9054), seguita a brevissima distanza dalla SVM (0,9043). Il KNN si è attestato su un valore significativamente inferiore (0,8056). Questo andamento evidenzia come Logistic Regression e SVM siano entrambi in grado di distinguere in modo efficace tra le due classi mentre il KNN presenta una capacità discriminante più limitata.

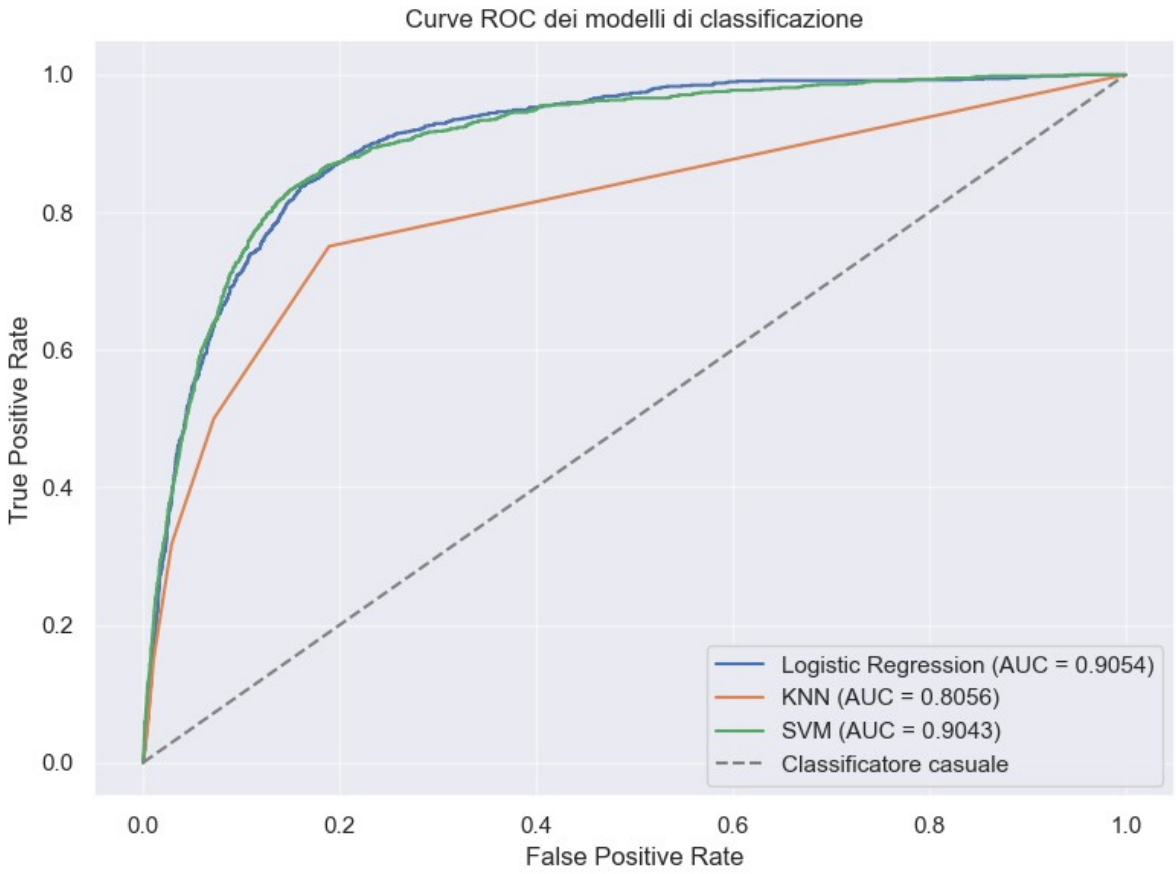

Figura 8: Curve ROC dei modelli di classificazione implementati

L'uso combinato di matrici di confusione e curve ROC ha quindi permesso di integrare la lettura delle metriche numeriche con una rappresentazione grafica più intuitiva del comportamento di tali modelli. Nel complesso, questa analisi conferma che la Logistic Regression rappresenta il miglior compromesso tra capacità discriminante e bilanciamento tra errori sulle due classi, mentre la SVM si conferma un modello molto competitivo ma più prudente nel riconoscimento della classe positiva.

5. Approccio di spiegabilità: SHAP

In alternativa all'implementazione di un modello di deep learning per il quinto punto della traccia progettuale è stato scelto un approccio di explainability basato su SHAP (SHapley Additive exPlanations). Questa scelta è stata effettuata con l'obiettivo di non limitare l'analisi alla sola valutazione delle prestazioni dei classificatori ma di approfondire anche il contributo delle singole feature alle decisioni del modello. La traccia prevede infatti esplicitamente la possibilità di adottare un metodo di spiegabilità come SHAP o LIME.

L'analisi SHAP è stata applicata al modello risultato migliore nelle fasi precedenti di valutazione quantitativa: la Logistic Regression, che ha ottenuto il miglior compromesso complessivo tra F1-score e ROC AUC.

SHAP assegna a ciascuna feature un contributo numerico rispetto alla predizione del modello, permettendo di interpretare sia il comportamento globale del classificatore sia quello di una singola osservazione. In questo modo è possibile distinguere: una spiegazione globale che evidenzia quali feature risultano mediamente più influenti nel comportamento del modello e una spiegazione locale che mostra come le singole variabili contribuiscano alla predizione di un caso specifico.

L'analisi globale, condotta mediante summary plot e bar plot, ha evidenziato che la feature più influente è la durata della chiamata effettuata al cliente (duration). Il risultato è particolarmente significativo poiché conferma quanto già discusso nella sezione introduttiva del progetto: la variabile duration possiede un elevato potere informativo ma introduce anche un possibile problema di data leakage, in quanto il suo valore è noto solo dopo l'interazione con il cliente e non risulta quindi disponibile in un contesto predittivo reale.

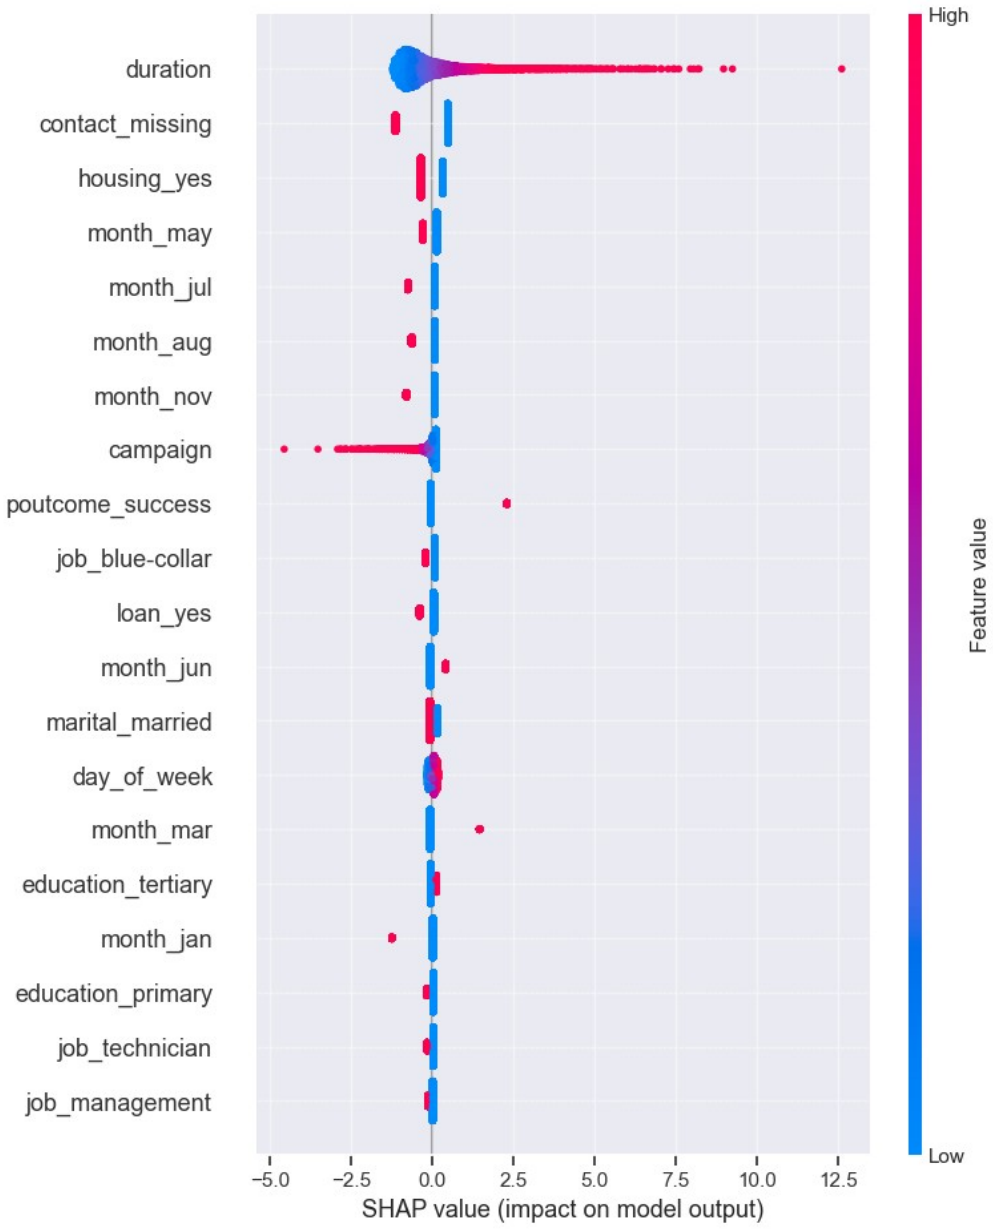

Figura 9: Summary plot SHAP

Nel summary plot si osserva inoltre che valori elevati di duration tendono a produrre contributi SHAP positivi, spingendo il modello verso la previsione della classe positiva, mentre valori più bassi tendono a contribuire in senso opposto. Questo comportamento è coerente con la natura stessa della variabile e con la forte associazione tra durata della chiamata e probabilità di sottoscrizione del deposito.

Accanto a duration, il modello attribuisce importanza rilevante anche ad altre feature, tra cui contact_missing, housing_yes, campaign, poutcome_success e alcune variabili legate al mese della

campagna. In particolare, la rilevanza di contact_missing suggerisce che l'assenza di informazione sul tipo di contatto non sia neutra rispetto al processo predittivo, ma venga utilizzata dal modello come segnale informativo. È importante sottolineare che questa osservazione ha valore interpretativo sul comportamento del classificatore e non implica necessariamente una relazione causale diretta tra la feature e l'esito della campagna.

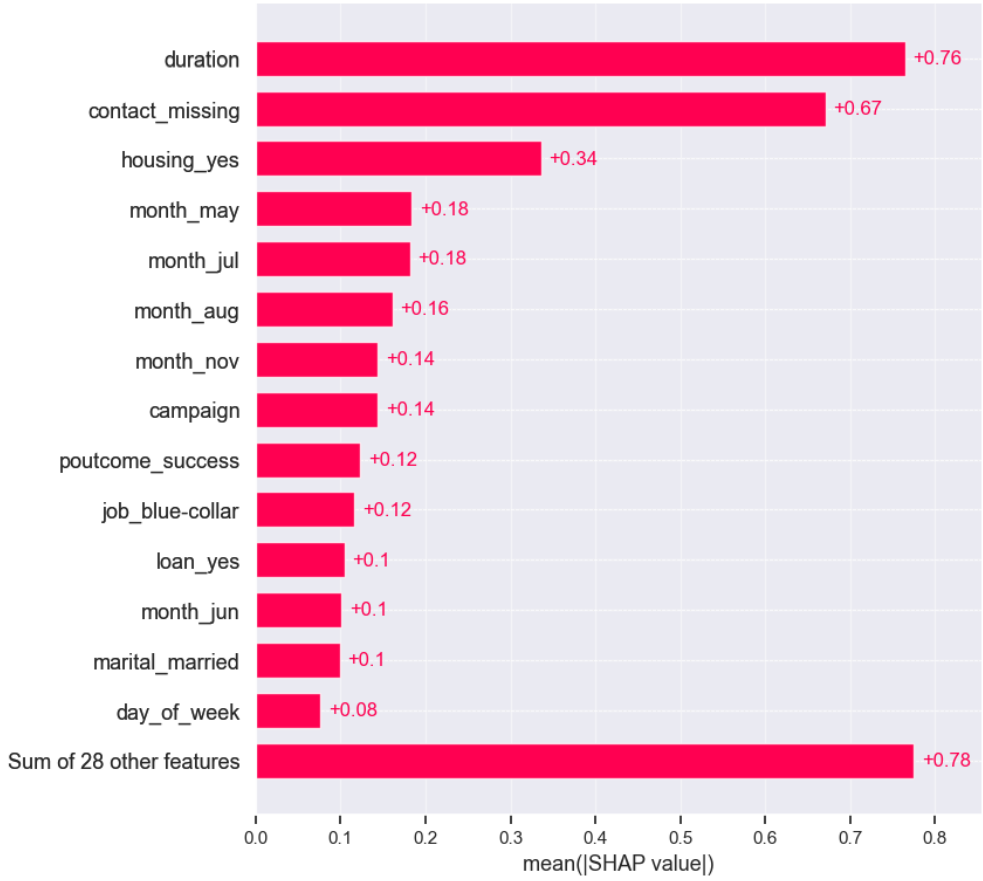

Figura 10: Bar plot globale SHAP

L'analisi locale, effettuata tramite waterfall plot su una singola osservazione del test set, ha permesso di visualizzare il contributo delle principali feature alla predizione individuale. In questo caso specifico, alcune variabili come contact_missing, loan_yes, housing_yes e alcuni mesi della campagna hanno spinto il modello verso la classe negativa. La duration ha fornito un contributo positivo ma non sufficiente a modificare la decisione finale.

Questa rappresentazione mostra chiaramente come la predizione del modello derivi dalla combinazione dei contributi di più feature e non dall'effetto isolato di una sola variabile.

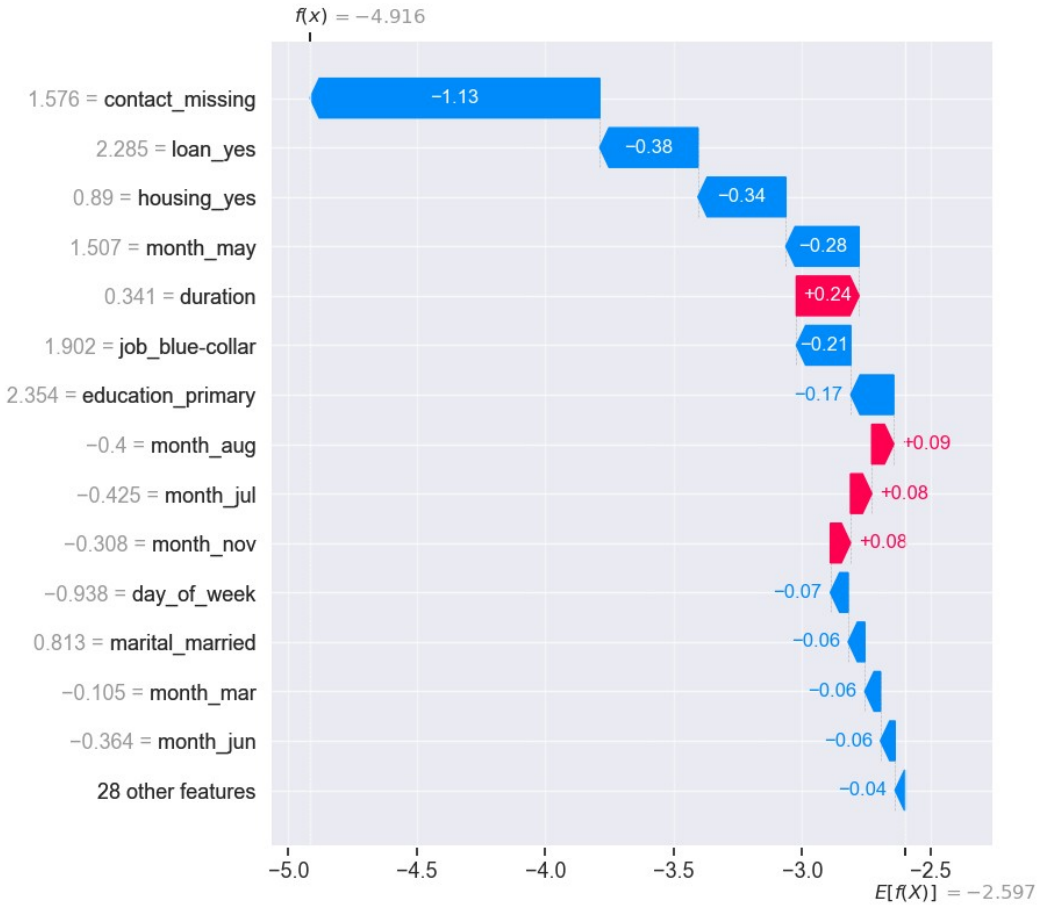

Figura 11: Waterfall plot locale

Nel complesso, l'analisi SHAP ha fornito un supporto interpretativo molto utile all'intero progetto. Se da un lato ha confermato la forte centralità di duration, rafforzando l'ipotesi che tale variabile condizioni in maniera significativa il comportamento del modello, dall'altro ha permesso di individuare ulteriori feature rilevanti e di comprendere meglio il processo decisionale del classificatore. Questo rende l'approccio basato su SHAP particolarmente adatto a completare la valutazione del modello, affiancando all'analisi delle prestazioni anche una lettura più trasparente e motivata delle sue decisioni.

6. Approfondimento: verifica della robustezza tramite cross-validation

Pur non essendo esplicitamente richiesta dalla traccia progettuale, è stata introdotta un'ulteriore analisi mediante cross-validation stratificata con l'obiettivo di ottenere una stima più robusta delle prestazioni dei modelli e ridurre la dipendenza da una singola suddivisione training/test.

La cross-validation rappresenta uno strumento utile per stimare in modo più affidabile la capacità di generalizzazione di un classificatore, soprattutto quando si desidera confrontare modelli diversi su più partizioni dei dati.

Nel progetto è stata utilizzata una procedura di Stratified K-Fold Cross Validation per preservare la distribuzione della variabile target all'interno dei diversi fold. Questa scelta risulta particolarmente opportuna nel caso del Bank Marketing Dataset, caratterizzato da una distribuzione sbilanciata delle classi. Per ciascun modello sono state considerate le metriche utilizzate nella valutazione principale, (accuracy, precision, recall, F1-score e ROC AUC).

I risultati medi della cross-validation confermano quanto già emerso nella valutazione del test set. In particolare, la SVM ha ottenuto il valore medio più elevato di ROC AUC, mentre la Logistic Regression ha mantenuto il miglior F1-score medio confermandosi come il classificatore più equilibrato nel compromesso tra precision e recall. Il KNN si è invece confermato il modello meno efficace anche nella valutazione incrociata.

Nel complesso, la cross-validation non modifica in maniera sostanziale le conclusioni dell'analisi principale ma le rafforza, mostrando che i risultati ottenuti non dipendono in modo critico da una singola partizione dei dati. Essa consente quindi di sostenere con maggiore solidità che Logistic Regression e SVM rappresentano i modelli più affidabili nel contesto del problema studiato, mentre il KNN risulta meno affidabile.

Conclusioni

Il presente progetto ha affrontato un problema di classificazione binaria sul Bank Marketing Dataset con l'obiettivo di prevedere la sottoscrizione di un deposito a termine a partire da informazioni anagrafiche, economiche e relative alle campagne di marketing precedenti. Il workflow sperimentale è stato sviluppato in coerenza con la traccia progettuale, comprendendo preprocessing dei dati, analisi esplorativa mediante PCA, implementazione di tre algoritmi di classificazione, valutazione quantitativa delle prestazioni, analisi tramite matrici di confusione e curve ROC e interpretazione del modello mediante SHAP.

L'analisi preliminare del dataset ha evidenziato una struttura eterogenea, caratterizzata dalla presenza di variabili numeriche e categoriche, nonché di valori mancanti in alcune feature categoriali. Questo ha reso necessaria una fase di preprocessing articolata, comprendente la gestione esplicita dei valori mancanti, la codifica delle variabili categoriche e la trasformazione del dataset in una rappresentazione interamente numerica, compatibile con le successive fasi di analisi e classificazione.

L'applicazione della PCA ha mostrato che le prime due componenti principali spiegano soltanto una quota limitata della varianza totale del dataset, pari al 13,59%, evidenziando come l'informazione non sia concentrata in poche dimensioni ma distribuita su un numero più ampio di componenti.

Per la fase di classificazione il confronto tra Logistic Regression, KNN e SVM ha evidenziato come i modelli più efficaci nel setting sperimentale considerato siano Logistic Regression e SVM, mentre il KNN ha evidenziato prestazioni inferiori. In particolare, la Logistic Regression è risultata il modello più solido in termini di compromesso complessivo, ottenendo i migliori valori sia di F1-score sia di ROC AUC. Questo risultato è particolarmente significativo in quanto conferma che l'accuracy da sola non costituisce un criterio sufficiente per la selezione del modello, soprattutto in presenza di una variabile target sbilanciata.

Le matrici di confusione e le curve ROC hanno ulteriormente confermato tale interpretazione. Tutti i modelli si sono mostrati efficaci nel riconoscimento della classe negativa e hanno incontrato maggiori difficoltà nell'identificazione della classe positiva, coerentemente con lo sbilanciamento del dataset. Anche in questa analisi la Logistic Regression ha mostrato il miglior equilibrio complessivo tra capacità discriminante e bilanciamento degli errori.

L'analisi di explainability mediante SHAP ha infine fornito un contributo interpretativo fondamentale. Questa ci ha permesso di capire le feature che influenzano maggiormente le decisioni del modello. In particolare, la variabile duration è risultata nettamente la più importante, confermando la criticità già evidenziata nella fase introduttiva. Essa possiede un elevato potere informativo ma introduce anche un potenziale problema di data leakage poiché il suo valore è disponibile solo al termine dell'interazione con il cliente.

In conclusione, possiamo affermare che il progetto ci ha permesso di costruire un processo di classificazione metodologicamente coerente, interpretabile e aderente ai contenuti del corso. Un possibile sviluppo futuro dell'analisi consiste nel confrontare le prestazioni dei modelli con e senza la variabile *duration*, così da verificare quanto essa influisca sul classificatore e ottenere una valutazione ancora più realistica del sistema in un contesto più concreto.